ESE5023 作业二：地球科学数据处理与分析报告

1. 显著地震（Significant earthquakes since 2150 B.C.）

本小题使用美国国家海洋与大气管理局（NOAA）NCEI 提供的全球显著地震数据集（Sig_Eqs.tsv），用 pandas 完成数据的读取、清洗、分组统计与绘图，对自公元前 2150 年以来的全球地震记录进行探索性分析。

原始数据包含年份（Year）、月份（Mo）、日期（Dy）、国家（Country）、地点、震级（Ms 等）、死亡人数（Deaths 与 Total Deaths）等 49 个字段，时间跨度极大。由于字段以文本形式混杂存在，读取时先按制表符分隔、统一以字符串读入（dtype=str），再对数值型字段逐一转换为数字，并处理掉其中的逗号与空格，为后续统计做准备。

1.1 各国地震累计死亡人数 Top 20

数据里有两个与死亡有关的字段——Deaths 和 Total Deaths。Total Deaths 通常是在一次地震基础上，把由地震引发的海啸、火灾等次生灾害造成的死亡也计入的总数，信息更完整，所以统计时优先采用 Total Deaths，该字段缺失时才用 Deaths 填补，避免因空值漏算。此外，同一个国家在原始数据中可能存在多种写法（如 USA、U.S.A.、UNITED STATES OF AMERICA），若直接分组会被当成不同国家。因此我先把国家名统一大写，并做别名规范化（如统一为 UNITED STATES、CHINA 等），再用 groupby 按国家求和、降序排序，取前 20 个输出。

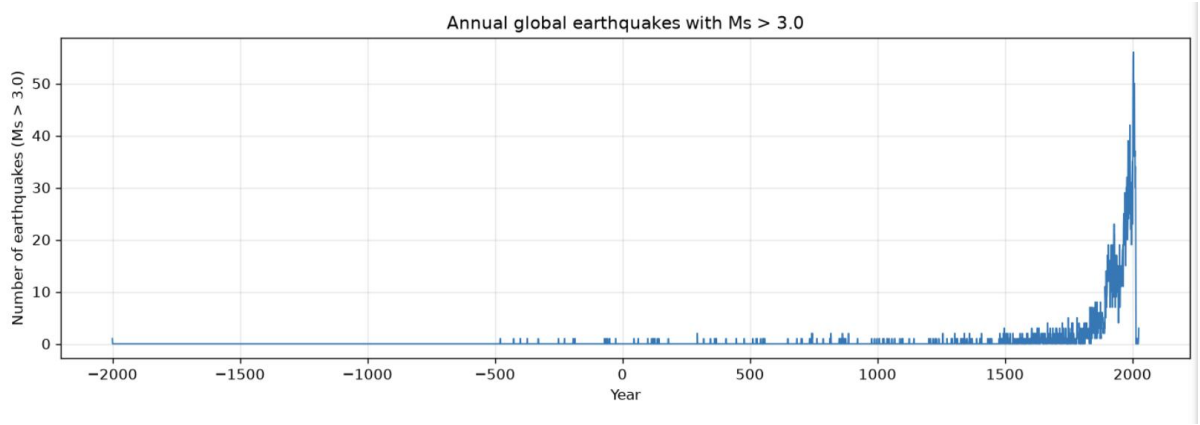
中国累计死亡人数最多，约 213.9 万；其次是土耳其（约 120.0 万）、伊朗（约 101.4 万）、意大利（约 50.2 万）、叙利亚（约 49.2 万）、日本（约 32.5 万）、海地（约 32.4 万）等。这些国家大多位于板块交界的地震带上，强震多发，加上人口密集、历史大地震频发，因此累计伤亡惨重，结果符合地球科学常识。

```
======================================================================
1.1 Top 20 countries by total earthquake deaths:
======================================================================
Country_norm
CHINA           2139196.0
TURKEY          1199721.0
IRAN            1014439.0
ITALY            501836.0
SYRIA            491826.0
JAPAN            325430.0
HAITI            323784.0
AZERBAIJAN       319251.0
INDONESIA        284272.0
ARMENIA          177890.0
PAKISTAN         145055.0
IRAQ             136200.0
ECUADOR          135496.0
TURKMENISTAN     117412.0
PERU             108809.0
ISRAEL            93388.0
GREECE            86197.0
PORTUGAL          83572.0
CHILE             70585.0
INDIA             63508.0
```

1.2 Ms 大于 3.0 级地震的全球年频次与趋势

先从数据中筛选出 Ms 震级列非空且大于 3.0 的记录，再按年份分组统计每年发生的地震条数，得到年度序列。由于早年很多年份没有任何记录，若直接参与趋势拟合会低估早期水平，所以我先把没有地震记录的年份补成 0，再用 scipy.stats.linregress 拟合一条线性趋势线，观察频次随时间的变化。

线性趋势的斜率为 0.0011 次/年，p 值极小（约 4.27×10^{-97}，统计上显著）。从年度序列图和趋势线都能看到，早期（公元前到中世纪）记录的 3.0 级以上地震很少，近几百年来数量快速上升。需要强调的是，这种上升主要是近代地震观测台网逐步完善、史料记录体系更加完整所致，更多的小震和远处地震被记录下来，并不代表真实的地震活动本身显著增多。因此对“趋势”的解释要谨慎，不能简单理解为全球地震活动在持续增强。



1.3 函数 CountEq_LargestEq 统计各国地震总数与最大地震

我编写了一个函数 CountEq_LargestEq(country)，输入国家名，返回两项：(a) 该国家自公元前 2150 年以来的地震总条数；(b) 该国家历史上最大地震的发生日期与地点。最大地震按 Mag（震级）列判定，且只在该国家震级有效的记录中寻找；为了防止个别国家所有记录都缺震级导致程序报错，函数里加入了空值判断，若完全没有有效震级则只返回条数并把日期标为“Unknown Date”。随后遍历文件中出现的全部国家，生成一张包含国家、地震总数、最大地震日期与地点的汇总表，并按地震总数降序排列。

结果显示中国地震记录最多（626 条），最大地震发生在 1668 年 7 月 25 日的山东；日本 429 条（最大为 2011-03-11 日本本州东海岸 3·11 大地震）、印度尼西亚 427 条（最大为 2004-12-26 苏门答腊西海岸海啸地震）、伊朗 385 条、土耳其 359 条等紧随其后，均处于环太平洋地震带或地中海—喜马拉雅地震带，强震频次高。布隆迪、赞比亚、马达加斯加等少数国家仅 1 条记录且缺少有效震级，被标记为日期未知，说明这些地区的历史地震资料相对匮乏。部分结果如下：

```
======================================================================
1.3 All countries sorted by total number of earthquakes (FULL OUTPUT):
======================================================================
```

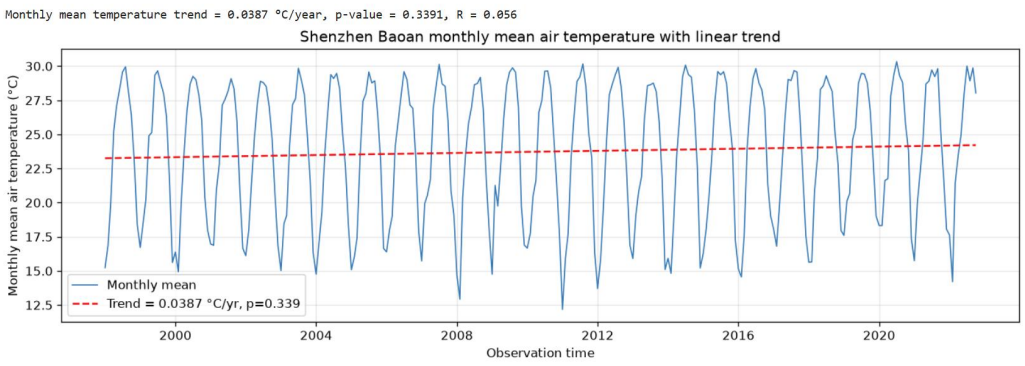
Country	Total_Earthquakes	Largest_Eq_Date	Largest_Eq_Location
CHINA	626	1668-07-25	CHINA: SHANDONG PROVINCE
JAPAN	429	2011-03-11	JAPAN: HONSHU
INDONESIA	427	2004-12-26	INDONESIA: SUMATRA: ACEH: OFF WEST COAST
IRAN	385	856-12-22	IRAN: DAMGHAN, QUMIS
TURKEY	359	1939-12-26	TURKEY: ERZINCAN
ITALY	338	1915-01-13	ITALY: MARSICA, AVEZZANO, ABRUZZI
GREECE	296	365-07-21	GREECE: CRETE: KNOSSOS
UNITED STATES	283	1964-03-28	ALASKA
PHILIPPINES	233	1897-09-21	PHILIPPINES: MINDANAO, ZAMBOANGA, SULU, ISABELA
MEXICO	217	1787-03-28	MEXICO: SAN MARCOS, OAXACA
CHILE	200	1960-05-22	CHILE: PUERTO MONTT, VALDIVIA
PERU	195	1716-02-06	PERU: PUEBLO DE TORATA IN TACNA
RUSSIA	159	1952-11-04	RUSSIA: KAMCHATKA PENINSULA
PAPUA NEW GUINEA	107	1919-05-06	PAPUA NEW GUINEA: SOLOMON ISLANDS
TAIWAN	103	1920-06-05	TAIWAN
INDIA	102	1950-08-15	INDIA-CHINA
COLOMBIA	83	1826-06-18	COLOMBIA: ENGATIVA,BOGOTA,RAMIRIQUI,UMBITA,TUNJA
AFGHANISTAN	72	1909-07-07	AFGHANISTAN: HINDU-KUSH
NEW ZEALAND	72	1826	NEW ZEALAND: FJORDLAND
ECUADOR	70	1906-01-31	ECUADOR: OFF COAST
VANUATU	65	1913-10-14	VANUATU ISLANDS

2. 深圳 1998—2022 年气温变化

本小题使用 NOAA 集成地表数据库（ISD）中深圳宝安机场站点（Baoan）的逐小时观测数据，时间跨度为 1998—2022 年，目标是探究站点月平均气温的季节变化与长期趋势。

原始数据共 235674 行、54 个字段。气温存放在 TMP 字段，其格式为“温度数值, 质控标记”，例如 “+0186,1”表示 18.6℃、质控标记为 1，因此不能直接参与数学计算。我先用正则把数值和质控码拆开，数值部分除以 10 还原为摄氏度得到新列 TMP_C，同时保留质控码。随后做质量过滤：只保留质控码为 0 或 1 的有效记录（剔除质控码为 9、2、5 等代表缺失或可疑的记录），再剔除超出物理合理范围（-90℃～60℃）的异常值，并将 DATE 解析为时间格式。最后把逐小时气温按月份重采样（resample）求月平均，得到 1998—2022 年的月平均气温序列，绘制时间序列并拟合线性趋势。

质控码分布显示，质控为 1（正常）的记录有 234863 条，质控为 9（缺失）797 条、2（可疑）13 条、5 有 1 条，过滤后有效记录 234863 条。月平均气温的线性趋势斜率为 0.0387℃/年，但 p 值为 0.339，未通过显著性检验（p>0.05），相关系数 R 仅 0.056，说明 1998—2022 年深圳月平均气温虽有微弱上升的信号，但在统计上并不显著。从时间序列可以清晰看到明显的年季节循环：夏季月均温高、冬季月均温低，这与深圳地处低纬、夏季受副热带高压和季风控制、气温高的气候特征是吻合的。



3. 全球热带气旋（Global collection of hurricanes）

本小题使用国际最佳热带气旋数据集 IBTrACS（v04r00），记录全球各机构整合的历史与近代热带气旋路径与强度信息，字段包括风暴编号 SID、名称 NAME、最大风速 WMO_WIND、洋盆 BASIN、季节 SEASON、经纬度 LAT/LON、观测时间 ISO_TIME 等。

读取时采用示例给出的参数——只读前 17 列、跳过第 2 行单位说明行（文件第 1 行列名、第 2 行为单位、第 3 行起为数据），把 ISO_TIME 解析为时间，并把 NOT_NAMED 等无意义标记识别为缺失值。此外经纬度在原始数据中带方向字符（如“12.5N”“165.4E”），我额外写了解析函数，把带 N/S/E/W 的字符串转换为带正负号的数值，WMO_WIND 也转为数值，为分组统计做准备。

3.1 按最大风速排名前 10 的风暴名称

先按风暴编号 SID 分组，提取每个风暴全程的最大 WMO_WIND 风速，再按风速降序取前 10，得到全球最强气旋榜单。

排名第一的是 2015 年的飓风 Patricia（最大风速 185 kn），其次是 1980 年 Allen（165 kn），2005 年 Wilma、1997 年 Linda、1988 年 Gilbert、1935 年无名风暴、2019 年 Dorian 并列（160 kn），2009 年 Rick、1998 年 Mitch、2017 年 Irma（155 kn）随后。榜单集中在 1980 年以后，说明近年观测与强度定级更完备，且这些均为超强气旋。

```
3.1 Top 10 largest hurricanes by maximum WMO_WIND:
                  SID      NAME  SEASON  WMO_WIND
665955  2015293N13266  PATRICIA    2015     185.0
427637  1980214N11330     ALLEN    1980     165.0
605747  2005289N18282     WILMA    2005     160.0
552460  1997253N12255     LINDA    1997     160.0
482075  1988253N12306   GILBERT    1988     160.0
178210  1935241N23291       NaN    1935     160.0
689333  2019236N10314    DORIAN    2019     160.0
629195  2009288N07267      RICK    2009     155.0
560438  1998295N12284     MITCH    1998     155.0
676144  2017242N16333      IRMA    2017     155.0
```

3.2 最强 20 个风暴的风速

按最大风速排序的 20 个 WMO_WIND 数值为 185、165、160×5、155×4、150×9。可以看出最强风暴的风速集中在 150～185 kn 的很高区间，从第 10 名往后风速明显下降到 150 kn 档并趋于集中，说明能被完整记录的超强气旋数量有限，强度上存在一个明显的“强者梯队”。

3.3 各洋盆的观测点数量统计

结论：按 BASIN 分组统计轨迹点数量，西北太平洋 WP 最多（236576 条），是全球热带气旋最活跃的海域；其次是南印度洋 SI（160668 条）、南太平洋 SP（67119 条）、东北太平洋 EP

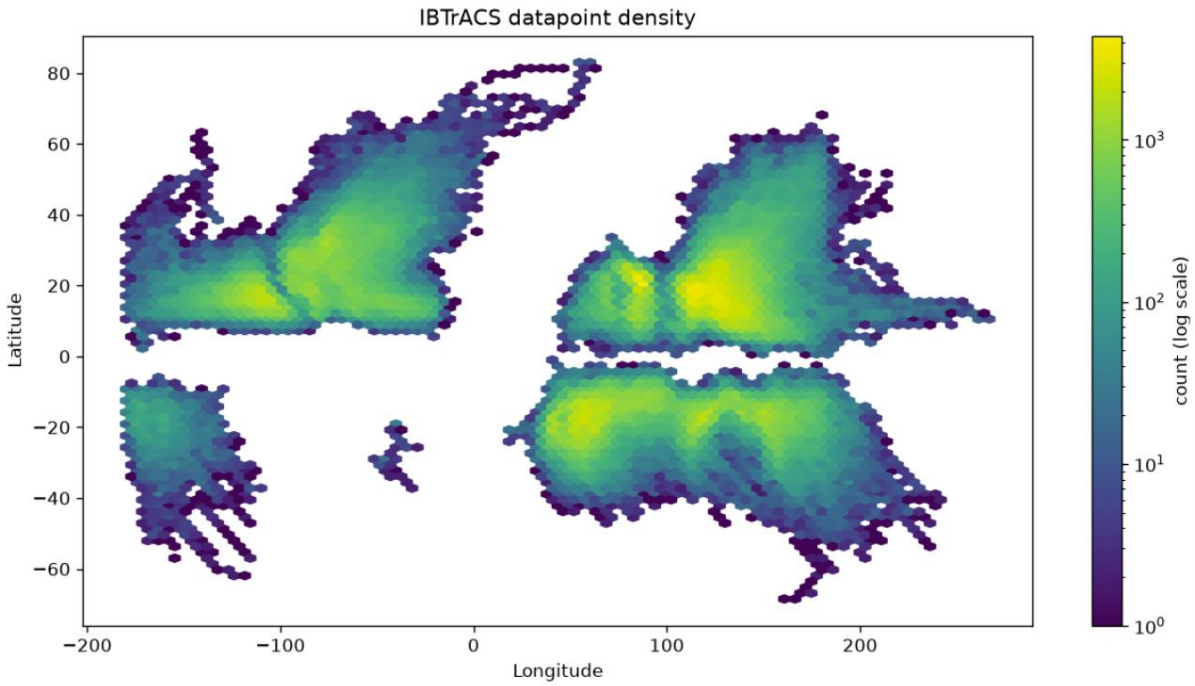
（62412 条）、北印度洋 NI（55402 条），南大西洋 SA 最少（仅 119 条）。此外还有一部分记录 BASIN 缺失（约 124881 条）。

```
3.3 Datapoint counts by Basin:
BASIN
WP     236576
SI     160668
NaN    124881
SP      67119
EP      62412
NI      55402
SA        119
Name: count, dtype: int64
```

3.4 气旋轨迹点经纬度空间分布

用 matplotlib 的 hexbin（六边形分箱）绘制全部轨迹点的经纬度密度图，颜色深浅代表该区域的轨迹点密集程度，并使用对数色标便于观察稀疏区的细节。

气旋轨迹点高度集中在各大洋的热带至副热带海域（纬度大致在 0°～40°），高纬度地区几乎没有记录，这与热带气旋只能在温暖的暖洋面上生成和维持的物理机制一致。



3.5 台风“山竹”（Mangkhut，2018）路径

筛选 2018 年、名称为 MANGKHUT 的记录（数据主要来自日本气象厅 TOKYO 机构），按时间排序并去重，绘制其经纬度路径并标注起点和终点。

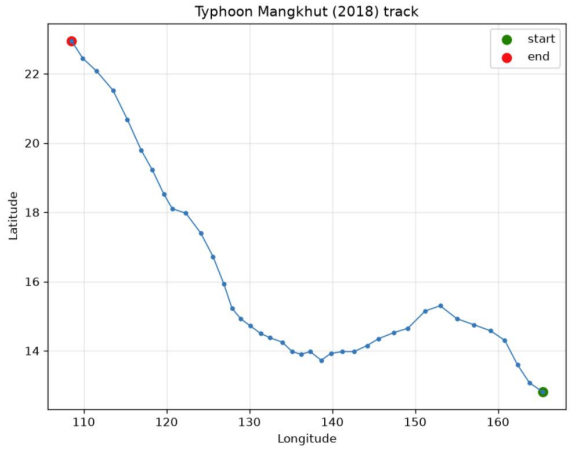
台风山竹于 2018-09-07 在西北太平洋生成（约 165°E 附近），随后整体向西北偏西方向移动，风速逐步增强至 110 kn 的巅峰强度，并于 09-16 前后登陆广东沿海（约 113.5°E、21.5°N 附近），之后强度快速减弱，09-17 观测结束。路径平滑向西移动，与 2018 年“山竹”的真实路径吻合。

3.5 Typhoon Mangkhut (2018) records:

	SID	NAME	ISO_TIME	LAT	LON	WMO_WIND
683027	2018250N12170	MANGKHUT	2018-09-07 12:00:00	12.820	165.367	35.0
683029	2018250N12170	MANGKHUT	2018-09-07 18:00:00	13.075	163.800	35.0
683031	2018250N12170	MANGKHUT	2018-09-08 00:00:00	13.600	162.350	40.0
683033	2018250N12170	MANGKHUT	2018-09-08 06:00:00	14.300	160.825	40.0
683035	2018250N12170	MANGKHUT	2018-09-08 12:00:00	14.575	159.125	45.0
683037	2018250N12170	MANGKHUT	2018-09-08 18:00:00	14.750	157.125	50.0
683039	2018250N12170	MANGKHUT	2018-09-09 00:00:00	14.925	155.050	65.0
683041	2018250N12170	MANGKHUT	2018-09-09 06:00:00	15.300	153.025	65.0
683043	2018250N12170	MANGKHUT	2018-09-09 12:00:00	15.150	151.225	70.0
683045	2018250N12170	MANGKHUT	2018-09-09 18:00:00	14.650	149.125	80.0
683047	2018250N12170	MANGKHUT	2018-09-10 00:00:00	14.525	147.450	80.0
683049	2018250N12170	MANGKHUT	2018-09-10 06:00:00	14.350	145.600	80.0
683051	2018250N12170	MANGKHUT	2018-09-10 12:00:00	14.150	144.200	85.0
683053	2018250N12170	MANGKHUT	2018-09-10 18:00:00	13.975	142.625	90.0
683055	2018250N12170	MANGKHUT	2018-09-11 00:00:00	13.975	141.225	95.0
683057	2018250N12170	MANGKHUT	2018-09-11 06:00:00	13.925	139.825	105.0
683059	2018250N12170	MANGKHUT	2018-09-11 12:00:00	13.725	138.675	110.0
683061	2018250N12170	MANGKHUT	2018-09-11 18:00:00	13.975	137.350	110.0
683063	2018250N12170	MANGKHUT	2018-09-12 00:00:00	13.900	136.225	110.0
683065	2018250N12170	MANGKHUT	2018-09-12 06:00:00	13.975	135.175	110.0
683067	2018250N12170	MANGKHUT	2018-09-12 12:00:00	14.250	133.950	110.0
683069	2018250N12170	MANGKHUT	2018-09-12 18:00:00	14.375	132.500	110.0
683071	2018250N12170	MANGKHUT	2018-09-13 00:00:00	14.500	131.350	110.0
683073	2018250N12170	MANGKHUT	2018-09-13 06:00:00	14.725	130.075	110.0
683075	2018250N12170	MANGKHUT	2018-09-13 12:00:00	14.925	128.950	110.0
683077	2018250N12170	MANGKHUT	2018-09-13 18:00:00	15.225	127.900	110.0
683079	2018250N12170	MANGKHUT	2018-09-14 00:00:00	15.925	126.925	110.0
683081	2018250N12170	MANGKHUT	2018-09-14 06:00:00	16.725	125.600	110.0
683083	2018250N12170	MANGKHUT	2018-09-14 12:00:00	17.400	124.125	110.0
683085	2018250N12170	MANGKHUT	2018-09-14 18:00:00	17.975	122.325	110.0
683087	2018250N12170	MANGKHUT	2018-09-15 00:00:00	18.100	120.700	90.0
683089	2018250N12170	MANGKHUT	2018-09-15 06:00:00	18.525	119.675	90.0
683091	2018250N12170	MANGKHUT	2018-09-15 12:00:00	19.225	118.275	85.0
683093	2018250N12170	MANGKHUT	2018-09-15 18:00:00	19.800	116.925	80.0
683095	2018250N12170	MANGKHUT	2018-09-16 00:00:00	20.675	115.275	75.0
683101	2018250N12170	MANGKHUT	2018-09-16 06:00:00	21.525	113.525	75.0
683107	2018250N12170	MANGKHUT	2018-09-16 12:00:00	22.075	111.550	65.0
683109	2018250N12170	MANGKHUT	2018-09-16 18:00:00	22.450	109.875	55.0
683111	2018250N12170	MANGKHUT	2018-09-17 00:00:00	22.950	108.525	45.0

3.6 筛选 1970 年以来西北太平洋与东北太平洋数据

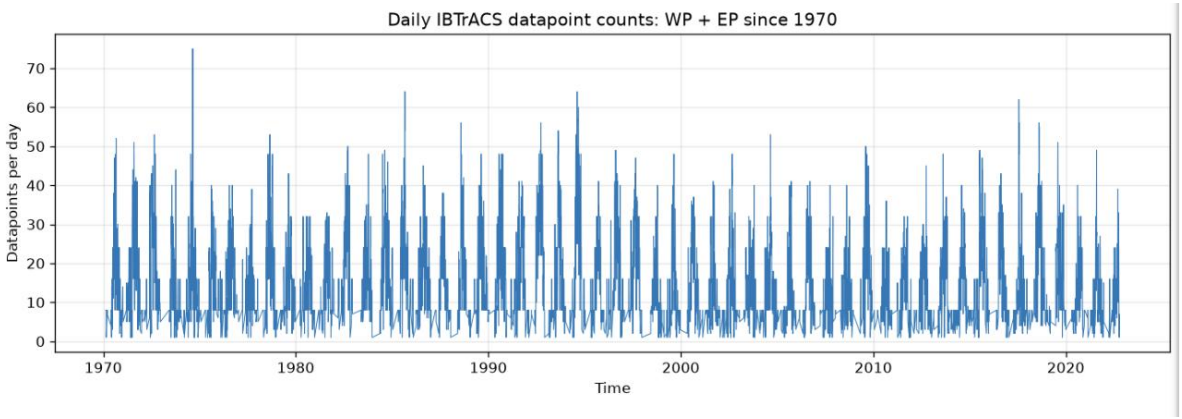
后续 3.7—3.10 的分析聚焦现代观测时期，因此构造一个新数据框 filtered，只保留 SEASON≥1970 且 BASIN 属于 WP（西北太平洋）或 EP（东北太平洋）的记录，并剔除没有观测时间的行，后续小题全部基于这份筛选数据。



3.7 每日气旋观测点数量

对筛选数据的 ISO_TIME 取日期，统计每一天的轨迹点数量，绘制逐日点位数量的时间序列。

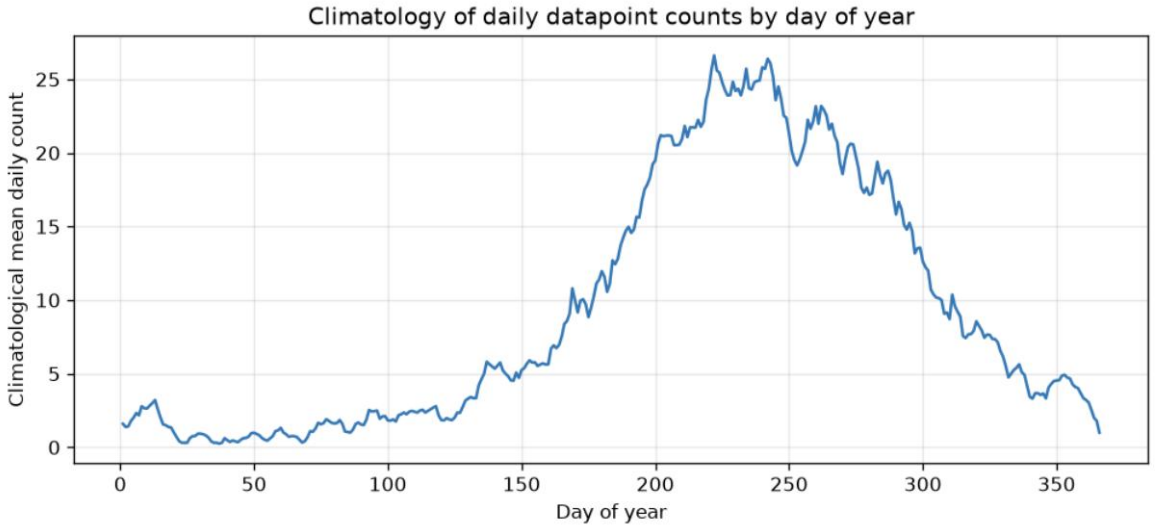
时间序列呈现明显的年际与季节起伏，不同日子的点位数量差异较大，点位多的日期代表当时海域气旋活动活跃。



3.8 按日序计算的气旋计数气候态

把每条记录换算成一年中的日序（day of year，1 月 1 日为第 1 天），再按日序分组求多年平均，得到一年中每一天的多年平均轨迹点数量，即气候态。

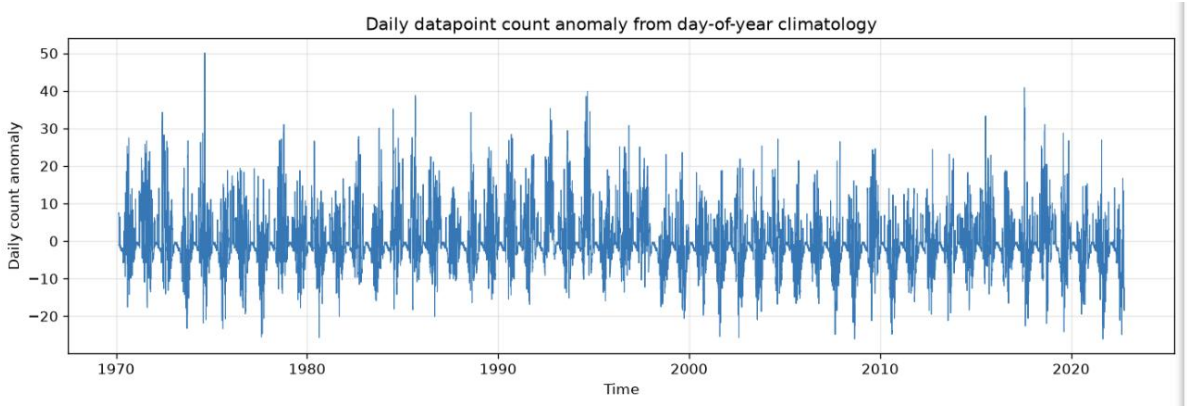
气候态曲线呈明显单峰形态，峰值出现在夏秋季（约 8—9 月），冬春季数值很低。这反映西北太平洋和东北太平洋的热带气旋具有强烈的季节特征：暖季海温升高、有利于气旋生成，活动频次高，冷季活动显著减弱。



3.9 日计数的距平（异常）

把每天的实际点位数量减去该日序对应的气候态平均值，得到距平序列。距平大于 0 表示当天活动高于多年平均，小于 0 表示低于平均。

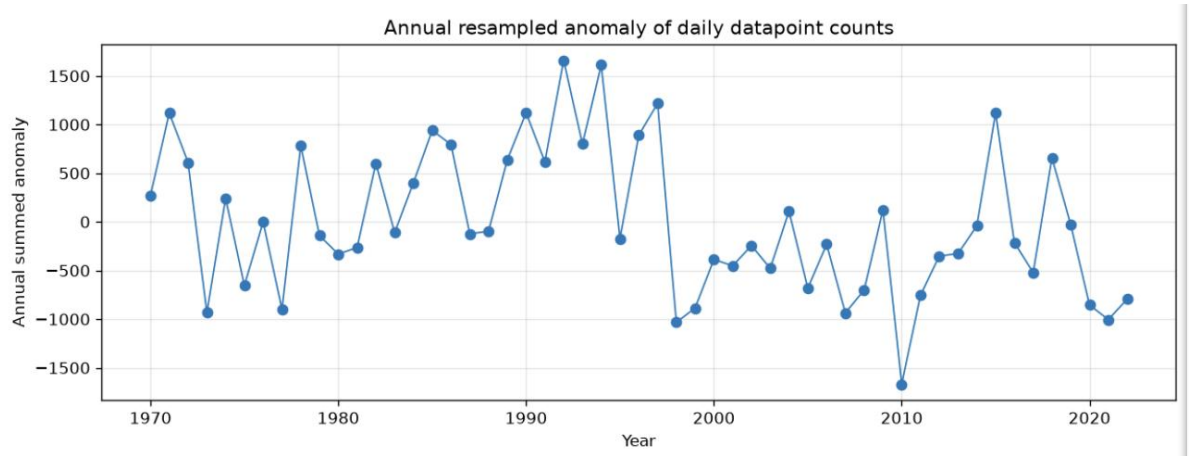
距平序列围绕 0 上下波动，能够突出单日相对多年气候平均的异常程度，便于识别哪些日子气旋活动明显偏多或偏少。



3.10 年度距平与异常年份

把逐日距平按年重采样求和，得到每一年的累计距平，衡量当年整体气旋活动相对气候平均的偏离量。

累计距平显著为正、即气旋活动异常偏多的年份包括 1992、1994、1997、1990、2015、1971 年等；累计距平显著为负、即活动异常偏少的年份包括 2010、1998、2021、2007、1973 年等。这些年份就是热带气旋活动明显异常的年份，通常与 ENSO 等大尺度气候模态的相位变化有关（如 El Niño 年西北太平洋气旋生成位置和频次常发生明显改变），可作为进一步研究的切入点。



）

4. 探索数据集（Explore a data set）

本小题从 NOAA NCEI 下载了全球历史气候网络逐日数据（GHCN-Daily）中站点 USW00014842（美国伊利诺伊州 General Wayne A. Downing 国际机场）的逐日气象数据，时间从 1943 年至今，包含日最高温、日最低温、降水等 大量逐日要素，我用 pandas 完成读取、清洗与统计分析。

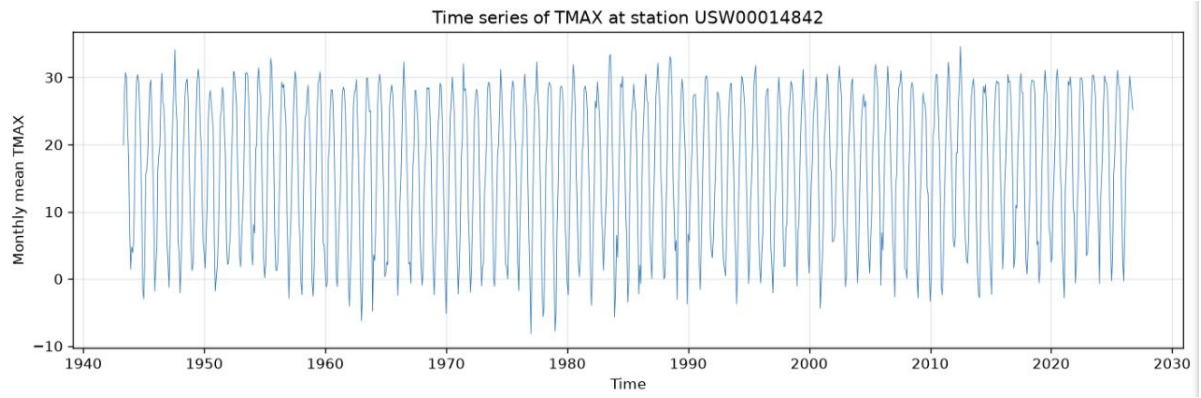
4.1 数据读取与清洗

文件列较多（118 列），程序先自动识别日期列（DATE）和首选数值变量，本小题选中 TMAX（日最高温）。GHCN 中 TMAX 是放大 10 倍存储的整数（单位 0.1℃），因此用数值转换后除以 10 还原为摄氏度；对带质控标记的变量剔除质控为 2、9 的坏记录，再删除缺失日期或变量的行，得到干净的日最高温序列。

清洗后 TMAX 的缺失率很低，约为 0.01%，绝大部分日期都有有效观测，数据质量良好。

4.2 时间序列

绘制日最高温时间序列可见非常明显的年周期波动——夏季温度高、冬季温度低，这是典型的温带大陆性气候特征（该站位于美国中西部内陆）。序列在多年尺度上还有一定的年际起伏。



4.3 统计检查与结论

为刻画 TMAX 的统计特征，我进行了 7 项简单统计检查，结果如下：

检查项	统计内容	结果与说明
1	缺失率	约 0.01%，数据质量好，缺失可忽略
2	描述性统计	样本 30475 天；均值 16.35℃，标准差 12.03℃；最小 -23.9℃、最大 40.6℃
3	IQR 异常值	四分位距（IQR）法判定异常值为 0 个，数据未见极端离群
4	月气候态	1 月最低（约 -0.03℃）、2 月 2.72℃、3 月 9.61℃，7 月最高（约 29.83℃），冬冷夏热
5	线性趋势	斜率约 0.0205℃/年，$p=7.96\times10^{-13}$，统计显著，长期有增暖信号
6	滞后 1 阶自相关	约 0.926，温度序列具有很强的连续性（记忆性）
7	偏度与峰度	偏度 -0.388、峰度 -0.863，分布近似对称、较平缓

从以上统计可归纳四点结论：其一，该站日最高温多年均值约 16.35℃，极端高温超过 40℃、严寒低于 -20℃，体现了中纬度大陆性气候的温度跨度大；其二，月气候态呈冬冷夏热的单峰分布，7 月最热、1 月最冷；其三，日最高温存在统计显著的长期增暖趋势（约 0.0205℃/年），反映出气候变暖背景下的升温信号，但由于滞后自相关很高（0.926），趋势的独立性需注意，统计上显著但仍属较弱的长期变化；其四，分布近似对称、异常值少，说明该序列总体平稳、质量可靠。