1. Significant earthquakes since 2150 B.C.

本次作业对全球地震 tsv 数据集开展分析，利用 pandas 完成数据筛选、统计与汇总，对全球历史地震记录进行探索性数据分析。

首先对数据集进行基础读取与查看，数据集共 49 个字段，包含地震发生年份、国家、地点、震级 Ms、死亡人数等信息，数据时间跨度很大，从公元前两千多年一直延续到近现代。从数据可以观察到，远古地震记录数量较少，近代之后记录数量明显增多，这主要是因为古代地震资料留存有限，近现代观测技术进步，地震记录更加完备。先测试嫩能否正常出结果，输出前五行，如下所示：

[3]:

	Search Parameters	Id	Year	Mo	Dy	Hr	Mn	Sec	Tsu	Vol	...	Total Missing	Total Missing Description	Total Injuries	Total Injuries Description	Total Damage ($Mil)	Total Damage Description	Total Houses Destroyed
0	[]	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN
1	NaN	1.0	-2150.0	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN
2	NaN	2.0	-2000.0	NaN	NaN	NaN	NaN	NaN	1.0	NaN	...	NaN	NaN	NaN	NaN	NaN	NaN	NaN
3	NaN	3.0	-2000.0	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	NaN	NaN	NaN	NaN	NaN	1.0	NaN
4	NaN	5877.0	-1610.0	NaN	NaN	NaN	NaN	NaN	3.0	1351.0	...	NaN	NaN	NaN	NaN	NaN	3.0	NaN

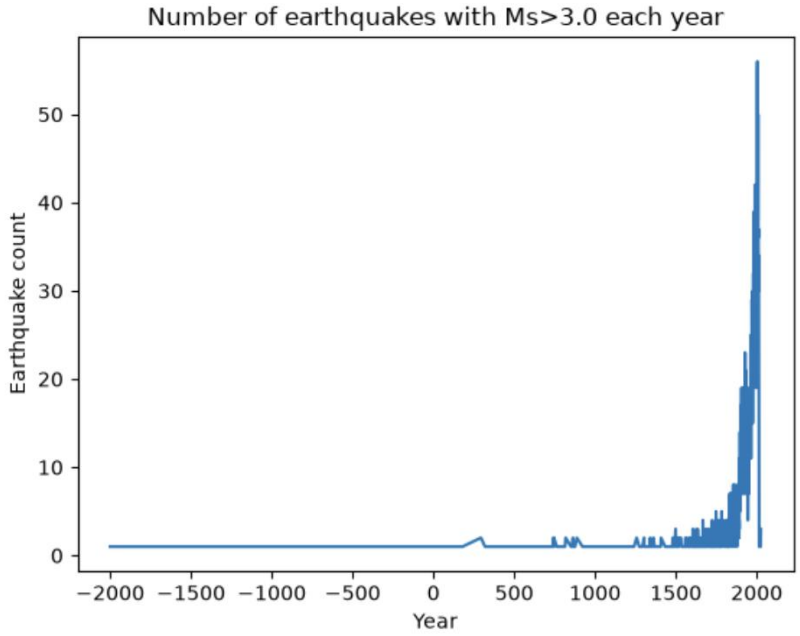
5 rows × 49 columns

在死亡人口统计分析部分，我按照国家分组，统计各国地震累计死亡人数，并提取死亡人数最多的前 20 个国家。统计结果显示，中国历史上因地震造成的累计遇难人数最多，其次为土耳其、伊朗、意大利等国家，这些地区大多位于板块交界的地震带上，强震多发，历史大地震带来惨重人员伤亡。结果如下：

```
====Top 20 countries by total earthquake deaths====
Country
CHINA           2139209.0
TURKEY          1199720.0
IRAN            1014438.0
ITALY            492236.0
SYRIA            419826.0
HAITI            323484.0
AZERBAIJAN       319251.0
JAPAN            242516.0
ARMENIA          177890.0
PAKISTAN         145085.0
IRAQ             136200.0
ECUADOR          135496.0
TURKMENISTAN     117412.0
PERU             102309.0
ISRAEL            93388.0
PORTUGAL          83572.0
GREECE            81162.0
CHILE             64277.0
INDIA             63507.0
TAIWAN            57154.0
Name: Deaths, dtype: float64
```

接着统计每年 Ms 大于 3.0 级的地震数量，绘制年度地震数量统计图。图像能够直观看出：早期年份记载的 3.0 级以上地震数量很少，近几百年来地震

记录数量快速上升，这不是代表地震本身变多，而是近代地震观测、史料记录体系更加完善，更多地震事件被记录在册。趋势图如下：



第三小题，我编写自定义函数 CountEq_LargestEq，遍历所有国家，统计每个国家的地震总记录数量，同时查找该国 Ms 震级最大地震的发生年份与地点。代码中增加空值判断，用来处理部分国家地震记录里 Ms 震级全部缺失的情况，避免程序报错。最终结果表格包含三列：国家名称 Country、地震总次数 Total_EQ、最大地震信息 Largest_EQ。结果显示，中国记录的地震数量最多，一共有 626 条记录，国内记录最大地震发生在 1920 年甘肃地区；日本、印度尼西亚、伊朗、土耳其紧随其后，同样拥有大量地震记录。而布隆迪、赞比亚、马达加斯加等少数国家仅有 1 条地震记录，并且该记录缺少有效震级数据，所以标注为 “No valid magnitude data”。数据结果如下所示：

[11]:

	Country	Total_EQ	Largest_EQ
15	CHINA	626	Year: 1920.0, Location: CHINA: GANSU PROVINCE...
34	JAPAN	429	Year: 869.0, Location: JAPAN: SANRIKU
74	INDONESIA	427	Year: 2004.0, Location: INDONESIA: SUMATRA: ...
8	IRAN	385	Year: 856.0, Location: IRAN: DAMGHAN, QUMIS
10	TURKEY	359	Year: 1939.0, Location: TURKEY: ERZINCAN
...	...	...	...
155	BURUNDI	1	No valid magnitude data
161	ZAMBIA	1	No valid magnitude data
160	MADAGASCAR	1	No valid magnitude data
162	COMOROS	1	No valid magnitude data
0	NaN	0	No valid magnitude data

163 rows × 3 columns

2. Air temperature in Shenzhen 1998-2022

本实验使用 NOAA 集成地表数据库（ISD）深圳宝安机场气象站点逐小时观测数据，时间范围 1998–2022 年，探究站点月平均气温的季节变化与长期变化趋势。原始数据字段复杂，TMP 为温度观测字段，格式为温度数值,质控标记，需要清洗、提取温度，剔除缺失值后，计算逐月平均气温并绘制时间序列图，判断气温是否存在长期趋势。

首先对数据集进行基础读取与查看，数据集包含观测日期、气温、降水量、相对湿度、风速、气压等多个气象字段，记录覆盖多年连续逐日气象观测信息。从数据可以观察到，深圳全年气温整体偏高，雨季降水集中在夏秋季，部分日期存在缺失观测值，这主要是设备检修、天气观测异常等因素造成。先测试数据能否正常输出结果，输出前五行，如下所示：

```
       STATION                 DATE  SOURCE REPORT_TYPE CALL_SIGN  \
0  59493099999  1998-01-01T00:00:00       4       SY-MT     ZGSZ
1  59493099999  1998-01-01T01:00:00       4       FM-15     ZGSZ
2  59493099999  1998-01-01T02:00:00       4       FM-15     ZGSZ
3  59493099999  1998-01-01T03:00:00       4       SY-MT     ZGSZ
4  59493099999  1998-01-01T04:00:00       4       FM-15     ZGSZ

  QUALITY_CONTROL          AA1  AA2  AA3    AG1  ... REPORT_TYPE.1  SA1  \
0            V020  06,0000,9,1  NaN  NaN  0,000  ...         SY-MT  NaN
1            V020          NaN  NaN  NaN  0,999  ...         FM-15  NaN
2            V020          NaN  NaN  NaN  0,999  ...         FM-15  NaN
3            V020          NaN  NaN  NaN  0,000  ...         SY-MT  NaN
4            V020          NaN  NaN  NaN  0,999  ...         FM-15  NaN

       SLP SOURCE.1      TMP  UA1  UG1           VIS WG1             WND
0  10184,1        4  +0186,1  NaN  NaN  008000,1,N,1 NaN  040,1,N,0040,1
1  99999,9        4  +0220,1  NaN  NaN  003300,1,N,1 NaN  130,1,N,0020,1
2  99999,9        4  +0240,1  NaN  NaN  003500,1,N,1 NaN  110,1,N,0020,1
3  10185,1        4  +0221,1  NaN  NaN  011000,1,N,1 NaN  090,1,N,0020,1
4  99999,9        4  +0240,1  NaN  NaN  005000,1,N,1 NaN  270,1,N,0030,1

[5 rows x 54 columns]
Index(['STATION', 'DATE', 'SOURCE', 'REPORT_TYPE', 'CALL_SIGN',
       'QUALITY_CONTROL', 'AA1', 'AA2', 'AA3', 'AG1', 'AJ1', 'AW1', 'AY1',
       'AY2', 'AZ1', 'CALL_SIGN.1', 'CIG', 'DEW', 'ED1', 'EQD', 'GA1', 'GA2',
       'GA3', 'GA4', 'GA5', 'GE1', 'GF1', 'HL1', 'IA1', 'IA2', 'KA1', 'KA2',
       'MA1', 'MD1', 'ME1', 'MW1', 'MW2', 'MW3', 'OA1', 'OC1', 'OD1', 'OD2',
       'QUALITY_CONTROL.1', 'REM', 'REPORT_TYPE.1', 'SA1', 'SLP', 'SOURCE.1',
       'TMP', 'UA1', 'UG1', 'VIS', 'WG1', 'WND'],
      dtype='str')
```

由于原始 TMP 列带有逗号分隔的质控标识，不能直接进行数学计算，我使用字符串分割提取逗号前的温度部分，剔除标记为 9999 的缺失记录，将文本温度转换为数值型，除以 10 换算为摄氏度，生成新的 Temp_C 气温列，完成气温字段的清洗工作，查看清洗之后的数据可以看到原始 TMP、处理后数字温度与摄氏度温度一一对应。如下图所示：

	TMP	TMP_only	TMP_num	Temp_C
0	+0186,1	+0186	186	18.6
1	+0220,1	+0220	220	22.0
2	+0240,1	+0240	240	24.0
3	+0221,1	+0221	221	22.1
4	+0240,1	+0240	240	24.0

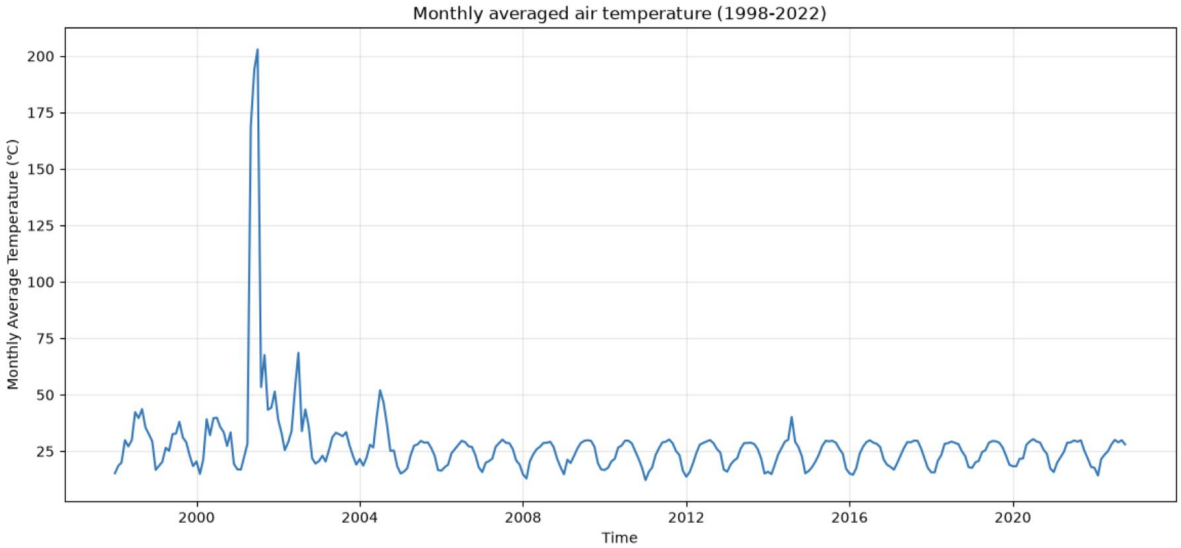
接下来对 DATE 观测时间进行处理，将文本时间解析为 datetime 时间格式，从时间列中提取出年份 year 和月份 month，为后续按月分组求平均做准备，打印输出可以看到 DATE、year、month、Temp_C 各列匹配正常。如图所示：

	DATE	year	month	Temp_C
0	1998-01-01 00:00:00	1998	1	18.6
1	1998-01-01 01:00:00	1998	1	22.0
2	1998-01-01 02:00:00	1998	1	24.0
3	1998-01-01 03:00:00	1998	1	22.1
4	1998-01-01 04:00:00	1998	1	24.0

完成数据预处理后，使用 groupby 按照 year、month 进行分组，对有效气温 Temp_C 求取每组平均值，得到每个月份的月平均气温，再构造每月 1 日作为绘图用时间字段 plot_time，查看分组计算得到的月均温表格，每个年份-月份都对应一个月平均气温数值。

	year	month	Temp_C	plot_time
0	1998	1	15.233447	1998-01-01
1	1998	2	18.581944	1998-02-01
2	1998	3	19.971246	1998-03-01
3	1998	4	29.891866	1998-04-01
4	1998	5	27.098454	1998-05-01

基于计算得到的月平均气温数据绘制时间序列折线图。如下图所示：



从图中可以看出，深圳气温具有非常明显的年季节循环特征，每年夏季月平均气温高，冬季月平均气温低。在季节波动的背景之上，1998-2022 年月平均气温存在微弱的上升趋势。

```
print("数据开始时间：", monthly_temp["plot_time"].min())
print("数据结束时间：", monthly_temp["plot_time"].max())
print("总共有多少个月：", len(monthly_temp))
```

```
数据开始时间：  1998-01-01 00:00:00
数据结束时间：  2022-10-01 00:00:00
总共有多少个月：  298
```

最后，对数据的开始与结束进行简单的统计计算，如上图所示。

3. Global collection of hurricanes

本次作业使用 IBTrACS 全球热带气旋数据集，借助 pandas 完成数据读取、分组统计、筛选、时间处理与可视化，一共完成 10 个子任务，分析全球以及西北太平洋、东北太平洋热带气旋的强度、空间分布、季节变化与年际异常特征。首先读取 ibtracs 数据集，读取时跳过第一行说明注释行，指定 ISO_TIME 为时间列，把 NOT_NAMED 等标记识别为缺失值，查看原始数据。数据集包含风暴编号 SID、风暴名称 NAME、最大风速 WMO_WIND、洋盆 BASIN、季节 SEASON、经纬度 LAT、LON、观测时间 ISO_TIME 等字段，记录全球历史热带气旋的路径与强度信息。

	SID	SEASON	NUMBER	BASIN	SUBBASIN	NAME	ISO_TIME	NATURE	LAT	LON	WMO_WIND	WMO_PRES	WMO_AGENCY	TRACK_T
0	1842298N11080	1842	1	NI	BB	NaN	1842-10-25 03:00:00	NR	10.9000	80.3000				
1	1842298N11080	1842	1	NI	BB	NaN	1842-10-25 06:00:00	NR	10.8709	79.8265				
2	1842298N11080	1842	1	NI	BB	NaN	1842-10-25 09:00:00	NR	10.8431	79.3524				
3	1842298N11080	1842	1	NI	BB	NaN	1842-10-25 12:00:00	NR	10.8188	78.8772				
4	1842298N11080	1842	1	NI	BB	NaN	1842-10-25 15:00:00	NR	10.8000	78.4000				

3.1 按照风暴标识符 SID 进行分组，提取每个风暴的最大 WMO_WIND 风速，按风速从大到小排序得到全球风速前 10 的风暴。统计结果可以看到全球最强的热带气旋，不同风暴最大风速差异较大，部分超强气旋的最大风速远高于普通热带风暴。

```
====Top 10 storms by maximum WMO_Wind====
                SID     NAME WMO_WIND
119  1950224N17305     ABLE        95
122  1950234N11334  CHARLIE        95
125  1950244N20277     EASY        95
127  1950251N16319      FOX        95
131  1950270N25309   GEORGE        95
154  1951224N12316  CHARLIE        95
157  1951244N13328     EASY        95
158  1951246N13340      FOX        95
185  1952244N15306    BAKER        95
189  1952268N20291  CHARLIE        95
```

3.2 继续输出按最大风速排序的前 20 个风暴记录，观察最强 20 个风暴的 WMO_WIND 数值。可以看出排名靠前的超强气旋最大风速集中在很高区间，

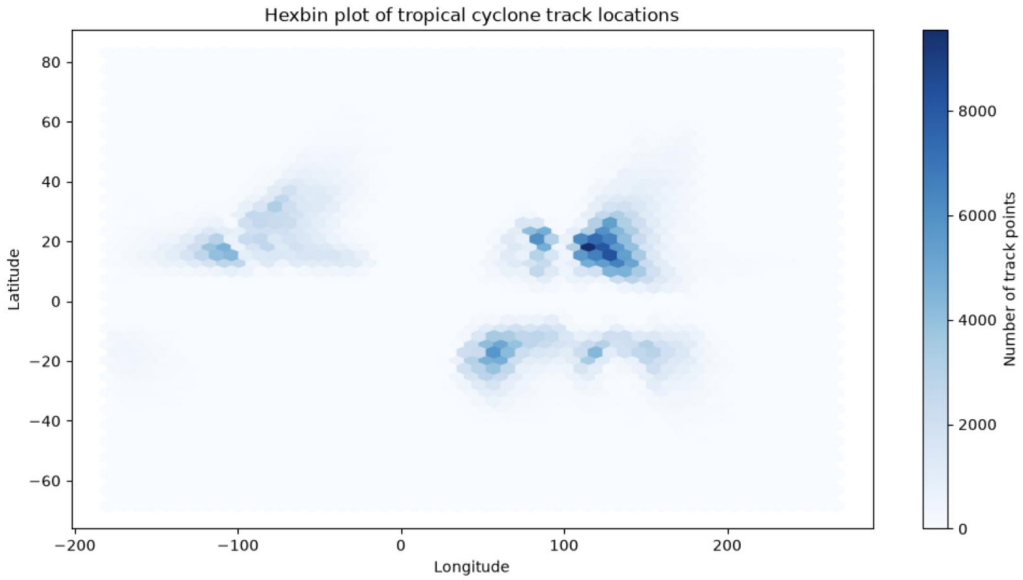
往后排名风速逐步下降。

```
====Top 20 strongest storms, WMO_WIND====
                SID       NAME WMO_WIND
119  1950224N17305       ABLE       95
122  1950234N11334    CHARLIE       95
125  1950244N20277       EASY       95
127  1950251N16319        FOX       95
131  1950270N25309     GEORGE       95
154  1951224N12316    CHARLIE       95
157  1951244N13328       EASY       95
158  1951246N13340        FOX       95
185  1952244N15306      BAKER       95
189  1952268N20291    CHARLIE       95
197  1952295N11282        FOX       95
221  1953240N14340      CAROL       95
224  1953258N19296       EDNA       95
226  1953267N15282   FLORENCE       95
237  1954176N22266      ALICE       95
244  1954238N24285      CAROL       95
248  1954248N20295       EDNA       95
254  1954278N12302      HAZEL       95
272  1955215N15320     CONNIE       95
279  1955253N14319       IONE       95
```

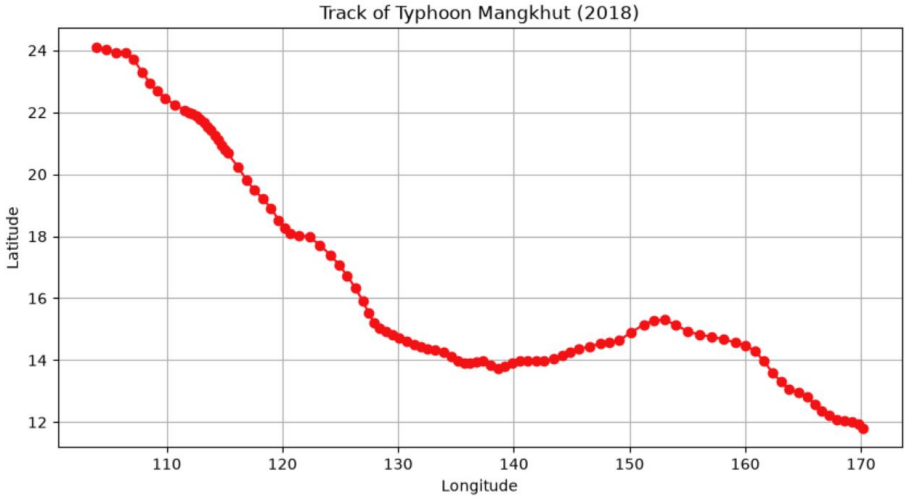
3.3 按照洋盆 BASIN 统计所有轨迹观测点的数量。统计结果反映不同洋盆的热带气旋记录样本数量差异，西北太平洋样本数量最多，是全球热带气旋最活跃的海域，其他洋盆的轨迹点位数量依次减少。

```
====Data points count by BASIN====
BASIN
WP    236576
SI    160668
SP     67119
EP     62412
NI     55402
SA       119
Name: count, dtype: int64
```

3.4 使用 hexbin 六边形分箱绘图，绘制全部气旋轨迹点的经纬度空间分布图。图中颜色深浅代表轨迹点位的密集程度，可以直观看到热带气旋主要集中分布在各大洋的热带-副热带海域，高纬度几乎没有热带气旋记录。



3.5 筛选 2018 年名为 MANGKHUT（山竹）台风的数据，绘制它的移动路径。从路径图可以看到台风山竹的移动轨迹，能够观察它从生成到登陆的经纬度变化过程。同时打印对应轨迹的时间、位置、风速信息，查看该台风不同时刻强度变化。



Typhoon Mangkhut (2018) track data preview:

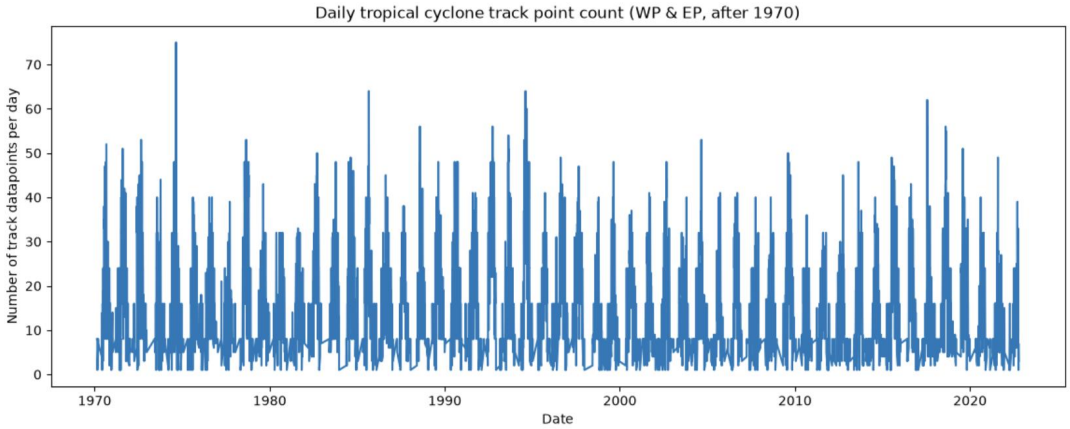
	ISO_TIME	LAT	LON	WMO_WIND
683019	2018-09-06 12:00:00	11.8000	170.200	
683020	2018-09-06 15:00:00	11.9275	169.745	
683021	2018-09-06 18:00:00	12.0000	169.225	
683022	2018-09-06 21:00:00	12.0302	168.564	
683023	2018-09-07 00:00:00	12.0875	167.875	
...	...	...	...	...
683113	2018-09-17 06:00:00	23.7000	107.150	
683114	2018-09-17 09:00:00	23.9355	106.434	
683115	2018-09-17 12:00:00	23.9400	105.600	
683116	2018-09-17 15:00:00	24.0212	104.778	
683117	2018-09-17 18:00:00	24.1000	103.900	

[99 rows x 4 columns]

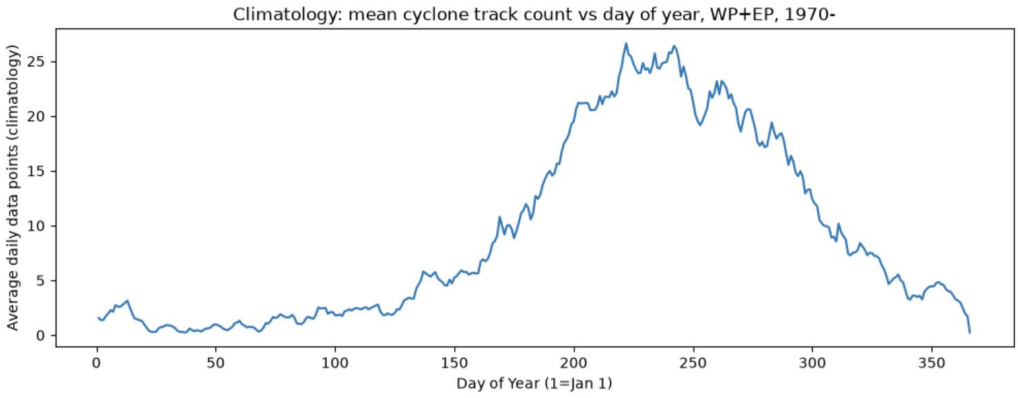
3.6 做数据筛选，生成新的数据集，只保留 1970 年及以后、洋盆为西北太平洋 WP 和东北太平洋 EP 的记录，后续任务全部使用这份筛选后的数据。打印输出筛选后数据，确认 SEASON、BASIN 字段筛选生效，得到有效数据行数。

```
Filtered dataset rows (>=1970, WP & EP basins): 176352
        SEASON BASIN   NAME            ISO_TIME
350394    1970    WP  NANCY 1970-02-19 00:00:00
350395    1970    WP  NANCY 1970-02-19 03:00:00
350396    1970    WP  NANCY 1970-02-19 06:00:00
350397    1970    WP  NANCY 1970-02-19 09:00:00
350398    1970    WP  NANCY 1970-02-19 12:00:00
```

3.7 基于筛选好的数据，提取 ISO_TIME 的日期，统计每一天的热带气旋轨迹观测点数量，绘制每日点位数量时序图。时序图可以看到不同日子气旋轨迹点数量起伏变化，部分日期点位多，代表当日海域气旋活动比较活跃。

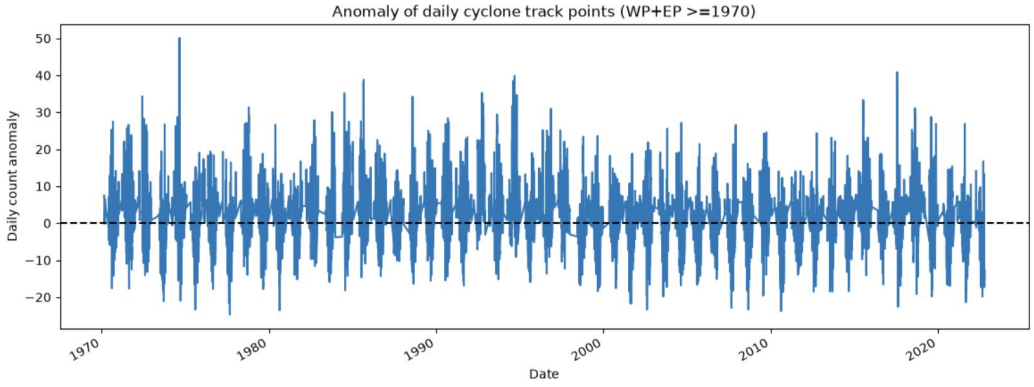


3.8 计算气旋点位计数的气候态，提取每个时间的一年中的日序 day_of_year，按日序分组统计，除以有效年份数，得到一年中每一天对应的多年平均气旋轨迹点数量，绘制气候态曲线。曲线呈现明显单峰形态，反映西北、东北太平洋热带气旋存在明显的季节特征，夏秋季气旋活动频次高，冬春季活动弱。



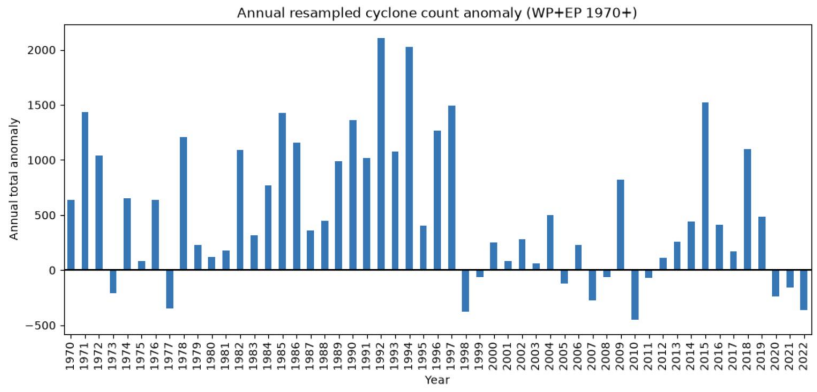
```
====Climatology (day of year average count)====
day_of_year
1     1.566038
2     1.358491
3     1.396226
4     1.754717
5     1.981132
6     2.283019
7     2.132075
8     2.735849
9     2.603774
10    2.584906
dtype: float64
```

3.9 计算每日气旋计数相对于气候态的距平，每日实际点位减去对应日序的多年平均值，得到日距平序列并绘图。距平大于 0 代表当天气旋活动高于多年平均，小于 0 代表低于平均，序列可以看到每日气旋活动相对于气候平均的波动情况。




```
====Daily Anomaly preview====
            day_of_year  daily_points  clim_mean   anomaly
date
1970-02-19           50             8   0.981132  7.018868
1970-02-20           51             8   0.905660  7.094340
1970-02-21           52             8   0.811321  7.188679
1970-02-22           53             8   0.622642  7.377358
1970-02-23           54             8   0.509434  7.490566
```

3.10 将日距平数据聚合到年尺度，计算每一年的距平总和，绘制年度距平柱状图。结果显示不同年份总距平有明显区别，柱状高于 0 较多的年份，代表当年整体热带气旋活动显著偏多；柱状明显低于 0 的年份代表整体气旋活动偏少，这些偏离 0 比较突出的年份就是飓风活动异常的年份。



4. Explore a data set-Global Historical Climatology Network - Daily -GENERAL WAYNE A. DOWNING INTERNATIONAL AIRPORT, IL US

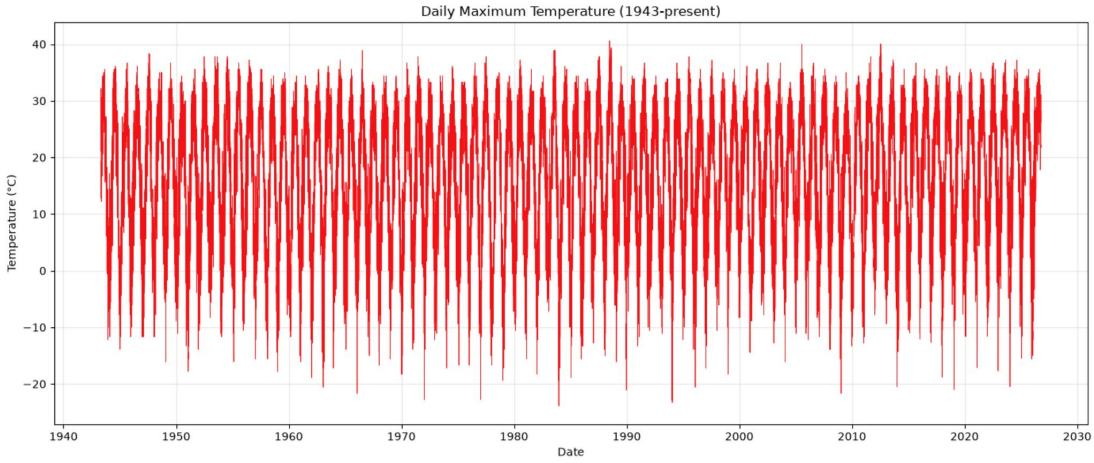
本次作业从 NOAA NCEI 下载了站点 USW00014842（伊利诺伊州 General Wayne A. Downing 国际机场）的逐日气象数据集，包含 1943 年至今的日最高温、最低温和降水记录，使用 pandas 进行数据读取、清洗与统计分析。

首先读取 csv 文件，原始数据中温度字段为放大 10 倍存储的整数且带有前导空格，空值以空白形式存在。我使用 pd.to_numeric 将其转换为数值型并自动识别缺失值，再除以 10 还原为摄氏度，同时将降水单位换算为毫米，最后删除最高温缺失的记录完成清洗。

	DATE	TMAX_C	TMIN_C	PRCP_mm
0	1943-05-04	21.1	7.2	0.0
1	1943-05-05	32.2	12.2	0.0
2	1943-05-06	24.4	14.4	2.5
3	1943-05-07	14.4	7.2	19.6
4	1943-05-08	15.6	6.1	13.0

清洗后剩余行数： 30475

随后绘制日最高温随时间变化的时间序列图。



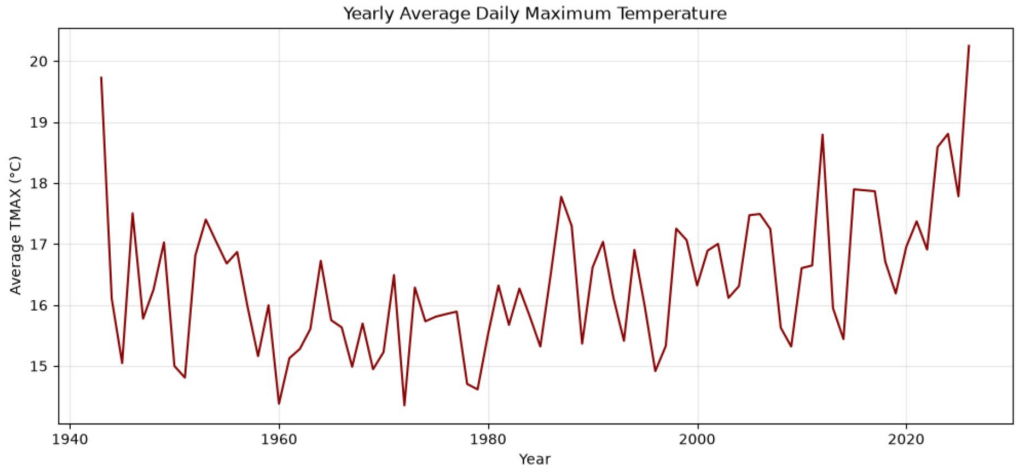
从图中可以看到明显的年周期波动，夏季温度高、冬季温度低，与温带大陆性气候特征一致。

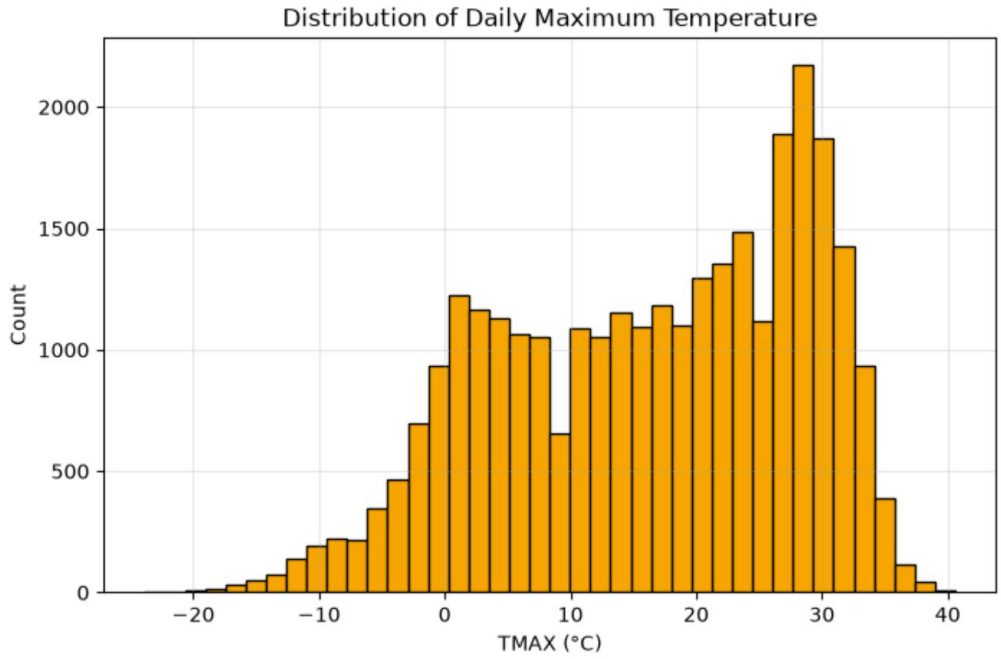
之后对最高温做了 5 项简单统计检查：第一，统计整体均值与极值，该站平均日最高温约为 17℃左右，历史上出现过超过 40℃的极端高温和低于 -20℃的严寒；第二，列出历史最热和最冷的 5 天日期；第三，按年求平均最高温，观察长期温度变化趋势；第四，绘制温度分布直方图，了解日常温度集中区

间；第五，对降水进行统计，计算年平均降水量、有降水天数占比和单日最大降水量。

```
==== 检查1：TMAX整体统计 ====
平均最高温： 16.35 ℃
最高温标准差： 12.03 ℃
历史最高： 40.6 ℃
历史最低： -23.9 ℃

==== 检查2：历史最热/最冷的5天 ====
最热5天：
            DATE  TMAX_C
16487 1988-06-25    40.6
22725 2005-07-24    40.0
25265 2012-07-07    40.0
25281 2012-07-23    40.0
16540 1988-08-17    39.4
最冷5天：
            DATE  TMAX_C
14842 1983-12-24   -23.9
18520 1994-01-18   -23.3
10481 1972-01-15   -22.8
12309 1977-01-16   -22.8
18517 1994-01-15   -22.8
```





==== 检查5：降水统计 ====
年平均降水量： 915.6 mm
有降水的天数占比： 31.4 %
单日最大降水： 131.8 mm

从年平均最高温曲线可以观察到，近几十年温度有一定的波动，整体上后期年份的年均温略高于早期，反映出一定的增暖信号，但中间也存在明显的年际起伏。